



Centro Politécnico Malvinas Argentinas.

CLASIFICACIÓN DE EVENTOS SÍSMICOS EN TIERRA DEL FUEGO

20
25

INFORME FINAL – APRENDIZAJE AUTOMÁTICO


Valeria Soledad Villegas

Tecnicatura en Ciencia de Datos e Inteligencia Artificial – 2° Año
Tierra del Fuego, Argentina

0. INTRODUCCIÓN

La sismicidad en la región de Tierra del Fuego representa un fenómeno natural de baja frecuencia pero con potencial impacto en la población. En este contexto, anticipar si un evento sísmico puede ser percibido por habitantes resulta valioso para la gestión del riesgo y la comunicación preventiva.

Este proyecto tiene como objetivo desarrollar un modelo de clasificación binaria que permita identificar, a partir de variables geofísicas, si un sismo es probable de ser sentido por la población. El trabajo se estructura en cuatro secciones principales: origen y preparación de los datos, análisis exploratorio, modelado y evaluación del desempeño, y conclusiones finales.



1. ORIGEN Y PREPARACIÓN DE LOS DATOS

1.1 FUENTE DE LOS DATOS

Para este proyecto se utilizó el **Catálogo Sismológico de Referencia de Tierra del Fuego – Complemento 2021–2024**, una base de datos oficial elaborada por la **Estación Astronómica Río Grande** en conjunto con la **Facultad de Ciencias Astronómicas y Geofísicas de la UNLP**, el **CONICET**, y con apoyo de estaciones de la **Red Sismológica Nacional de Chile**. Este catálogo continúa la serie iniciada en 2007 y constituye una fuente confiable y rigurosamente validada para el estudio de la sismicidad fueguina.

Los eventos sísmicos fueron procesados mediante el software especializado SEISAN (versión 12.0), utilizando el algoritmo HYPOCENTER, ampliamente empleado a nivel internacional para la localización de sismos. Las coordenadas hipocentrales (latitud, longitud, profundidad), la magnitud local (ML), y la hora de origen fueron determinadas a partir del análisis de fases sísmicas P y S, utilizando un modelo de velocidades ajustado a la estructura cortical de la Patagonia sur.

1.2 ESTRUCTURA DEL DATASET ORIGINAL

El dataset inicial contiene registros detallados de eventos ocurridos entre enero de 2021 y marzo de 2024. Para cada sismo se incluye:

- **Fecha y hora del evento** (Año, mes, día, hora, minuto, segundo).
- **Ubicación geográfica:** latitud y longitud del epicentro.
- **Profundidad del foco** (en km).
- **Magnitud local (ML).**
- **Número de estaciones** que registraron el evento.
- **Cobertura azimutal (GAP)** y errores asociados a la localización.
- **Clasificación por distancia** (Local, Regional, Distante).

1.3 PREPARACIÓN Y ENRIQUECIMIENTO DE LOS DATOS

A partir del dataset original del catálogo sismológico, se llevó a cabo un proceso detallado de limpieza, estandarización y enriquecimiento con el objetivo de preparar los datos para su análisis exploratorio y modelado supervisado.

Las principales tareas realizadas fueron:

- **Limpieza de datos:** se eliminaron registros con valores nulos en variables clave como la magnitud local (**magnitud_ml**). Además, se estandarizó la columna de profundidad (**profundidad_km**) para remover sufijos no numéricos y garantizar el formato flotante requerido para el análisis.
- **Conversión de tipos de datos:** se aplicaron conversiones de tipo para asegurar la interpretación correcta de columnas numéricas y facilitar su escalado posterior.
- **Definición de la variable objetivo (percibido):** se construyó una variable binaria basada en dos condiciones: que la magnitud local (ML) sea **igual o superior a 3.5**, y que la **distancia mínima al centro urbano más cercano sea de 250 km o menos**. Esta lógica se fundamenta en la relación entre energía liberada y cercanía al área poblada, como aproximación a la percepción humana de los eventos sísmicos.
- **Estandarización de variables temporales:** si bien el dataset ya incluía año, mes, día y hora del evento, estas columnas fueron renombradas y reorganizadas para facilitar su análisis y posterior uso en el modelo. Esto permitió identificar patrones temporales y evaluar, por ejemplo, la distribución mensual o la franja horaria de ocurrencia de sismos relevantes.
- **Cálculo de distancias geográficas:** se determinó la distancia entre el epicentro de cada evento y las tres principales ciudades fueguinas —**Ushuaia, Río Grande y Tolhuin**— utilizando fórmulas basadas en coordenadas geográficas. La menor de estas distancias se almacenó en la variable **distancia_min_km**, utilizada luego para definir el nivel de significancia de los eventos.

Este conjunto de transformaciones aseguró un dataset robusto, coherente y contextualizado, adecuado para abordar el problema de clasificación binaria planteado en los objetivos del proyecto.


2. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

El análisis exploratorio se centró en comprender la distribución y comportamiento de las variables clave involucradas en la predicción de eventos sísmicos percibidos. Se aplicaron técnicas visuales y estadísticas básicas para identificar patrones, anomalías y relaciones relevantes entre variables.




2.1 DISTRIBUCIÓN DE MAGNITUD LOCAL (ML)

Se graficó un histograma de la variable **magnitud_ml**, evidenciando que la mayoría de los eventos registrados se concentran entre 2.0 y 3.9. Sólo una fracción menor supera el umbral de 3.5, criterio adoptado para definir un evento como **percibido**. Esta observación fue clave para la construcción de la variable objetivo.



2.2 PROFUNDIDAD DE LOS EVENTOS

Se analizó la variable **profundidad_km** utilizando un gráfico boxplot. Este permitió visualizar la distribución general de profundidades y detectar valores atípicos. La mayoría de los sismos se concentran en zonas superficiales, típicamente menores a 20 km, aunque se observaron outliers por encima de los 60 km. Este comportamiento se relaciona con la metodología del INPRES, que asigna profundidades estándar cuando no es posible calcularlas con precisión.



2.3 EXPLORACIÓN DE OTRAS VARIABLES

Durante la limpieza de datos, se estandarizaron variables temporales como mes, hora, año, entre otras. Aunque no se generaron gráficos específicos para cada una, se revisaron sus distribuciones y consistencia. Estas variables fueron luego utilizadas en la etapa de modelado para evaluar su capacidad predictiva.

2.4 VARIABLE OBJETIVO: “PERCIBIDO”


La variable **percibido** fue creada a partir de dos criterios: magnitud mayor o igual a 3.5 y distancia mínima al centro urbano menor o igual a 250 km. Se verificó su distribución mediante conteo de clases, revelando **un moderado desbalance**, con predominancia de eventos no percibidos. Este aspecto fue tenido en cuenta para la elección de métricas de evaluación más robustas en la fase de modelado.

3. MODELADO Y EVALUACIÓN DEL DESEMPEÑO

3.1 SELECCIÓN DE VARIABLES Y ANÁLISIS DE CORRELACIÓN

Antes de entrenar los modelos, se construyó una **matriz de correlación** para analizar la relación entre variables numéricas. Esta visualización permitió:


- Alta correlación entre las variables de distancia a centros urbanos, lo cual justificó el uso de **distancia_min_km** como resumen.
- Asociación directa entre **magnitud_ml**, **distancia_min_km** y la variable objetivo percibido, validando su inclusión como principales predictores.



3.2 ESCALADO DE VARIABLES

Se aplicó **escalado estándar (StandardScaler)** a las variables numéricas, condición necesaria para algoritmos como SVM y Regresión Logística. Se utilizaron boxplots para visualizar la distribución de las variables transformadas, observando:

- Distribuciones centradas sin distorsión significativa.
- Presencia de outliers esperables debido a la naturaleza geofísica de los datos.



3.3 MODELOS ENTRENADOS

Se entrenaron y compararon tres modelos de clasificación:

MODELO	OBSERVACIONES
SVM (CON Y SIN OPTIMAZACIÓN)	Se probó con kernel RBF, con y sin GridSearchCV. Presentó buen accuracy general, pero no logró predecir casos positivos.
REGRESIÓN LOGÍSTICA	Interpretabilidad alta, pero sin capacidad de detectar la clase minoritaria.
RANDOM FOREST	El único modelo que logró predecir eventos percibidos con precisión aceptable. Mostró mayor robustez ante desbalance.

3.4 MÉTRICAS DE EVALUACIÓN

Se utilizaron métricas detalladas por clase: **precision, recall, F1-score y ROC AUC**, enfocándose especialmente en la clase minoritaria (1 = percibido).

MODELO	ACCURACY	PRECISION (1)	RECALL (1)	F1-SCORE (1)	ROCAUC
SVM	0.957	0.000	0.000	0.000	0.685
R. LOGÍSTICA	0.957	0.000	0.000	0.000	0.363
RANDOM F.	0.968	0.500	0.333	0.400	0.861

A pesar de que SVM y Regresión Logística presentaron accuracy alto, ambos fallaron completamente en detectar eventos percibidos. Esto evidencia la importancia de no confiar únicamente en el accuracy, especialmente en datasets desbalanceados.

3.5 IMPORTANCIA DE VARIABLES

En el modelo Random Forest, se evaluó la **importancia relativa de cada variable**. Las más relevantes fueron:

1 - dist_ushuaia

2 - dist_tolhuin

3 - longitud

4 - distancia_min_km

5 - latitud

Esto confirma que la **ubicación geográfica** y la **proximidad a zonas urbanas** son factores determinantes para estimar si un sismo será percibido.

3.6 CONCLUSIÓN TÉCNICA

De los modelos probados, **Random Forest fue el único que logró capturar parcialmente la clase minoritaria**, mostrando un desempeño general aceptable para este tipo de problema. Si bien los valores absolutos de precisión y recall en clase 1 no fueron altos, el **AUC de 0.861** respalda su capacidad de discriminación. Por lo tanto, fue seleccionado como el modelo final del proyecto.

4. CONCLUSIONES FINALES

Este proyecto tuvo como objetivo desarrollar un modelo de clasificación binaria que permita determinar si un evento sísmico registrado en la provincia de Tierra del Fuego puede ser considerado **percibido**, combinando variables clave como la magnitud del sismo y su proximidad a zonas urbanas. Para ello, se partió de un dataset oficial del INPRES (2021–2024), el cual fue limpiado, estructurado y enriquecido para su uso en algoritmos de aprendizaje automático.

Durante el proceso se aplicaron análisis exploratorios y evaluaciones de correlación que permitieron validar la relevancia de las variables seleccionadas. Posteriormente, se entrenaron distintos modelos de clasificación, incluyendo Regresión Logística, SVM y Random Forest. Si bien algunos modelos alcanzaron altos niveles de precisión general, sólo Random Forest logró identificar de forma parcial los casos positivos (eventos percibidos), demostrando mayor sensibilidad ante el desbalance de clases. Fue seleccionado como modelo final por su mejor desempeño en métricas como F1-score, ROC AUC y precisión específica en la clase minoritaria.

Los resultados obtenidos muestran que, aún en contextos con limitaciones de datos y alta desproporción entre clases, es posible construir modelos que aporten información valiosa para la caracterización de eventos relevantes. Este tipo de herramientas, si se integran a sistemas de monitoreo o de análisis local, pueden fortalecer la capacidad de anticipación, interpretación y comunicación del riesgo sísmico, especialmente en regiones con actividad frecuente pero de bajo impacto aparente, como Tierra del Fuego.

En síntesis, este trabajo demuestra cómo el uso responsable de datos y técnicas de aprendizaje automático puede potenciar las capacidades locales de anticipación y respuesta ante fenómenos naturales, incluso en contextos geográficos desafiantes y con limitaciones de datos.

5. TRABAJO FUTURO

El modelo desarrollado representa un primer paso hacia la incorporación de inteligencia artificial en el monitoreo sísmico local. No obstante, existen múltiples oportunidades de mejora.

Una línea de trabajo futura podría incluir la aplicación de técnicas de balanceo como SMOTE, que permitirían mejorar la detección de la clase minoritaria sin sacrificar precisión general. Asimismo, se podrían incorporar nuevas variables relacionadas con la percepción humana (intensidad instrumental, duración del evento, tipo de suelo) o con aspectos demográficos de los centros urbanos afectados.

Por otro lado, el modelo podría adaptarse para funcionar en tiempo real dentro de sistemas de alerta, integrándose con sensores activos y canales de comunicación ciudadana.

Estos desarrollos futuros podrían ampliar el impacto práctico del proyecto, contribuyendo a una mayor resiliencia sísmica en la región fueguina.