

Informe Final del Proyecto de Aprendizaje Automático

Matias Oroz

Politecnico Malvinas Argentina

Introducción

El presente trabajo se enmarca en el parcial de la materia Aprendizaje Automático del Politécnico Malvinas Argentinas. El objetivo general es aplicar las técnicas vistas en clase sobre un problema real, utilizando datos públicos y respetando una estructura de proyecto reproducible.

Elegí trabajar con datos del Parque Nacional Tierra del Fuego porque me parece importante abordar problemáticas vinculadas con la provincia de Tierra del Fuego y su entorno natural. El parque es un destino turístico emblemático, y entender mejor su estacionalidad y nivel de actividad puede ser útil tanto para la planificación pública como para el sector privado (alojamientos, transporte, servicios turísticos).

El objetivo específico del proyecto es predecir el nivel de actividad turística del parque para el mes siguiente, clasificándolo en tres categorías: Alta, Media y Baja temporada. Además, se analiza de forma complementaria el perfil de visitante predominante (Residente / No Residente) para entender mejor quiénes visitan el parque en cada momento del año.

Datos utilizados y relevancia

2.1 Origen de los datos

Todos los datos utilizados provienen del Instituto Provincial de Análisis e Investigación, Estadística y Censos (IPIEC) de Tierra del Fuego. Esta elección garantiza datos oficiales y consistentes, actualización periódica y relevancia directa para el análisis turístico de la provincia.

Se utilizaron tres datasets:

Visitas al Parque Nacional Tierra del Fuego

Archivo: 16_1_04_Visitas-al-Parque-Nacional-TDF.xlsx

Contenido: cantidad de visitas mensuales al parque, discriminadas en residentes y no residentes.

Período utilizado: 2015–2026.

Pernoctaciones e ingreso de viajeros en Ushuaia

Archivo: 16_1_01_Pernoctaciones_ingresos_estadia_promedio.xlsx

Contenido: pernoctaciones totales, cantidad de viajeros y estadía promedio en Ushuaia.

Período utilizado: 2015–2025.

Meteorología: temperatura y precipitaciones

Archivo: 22_2_01_Meteorologia_Temperatura_Precipitaciones.xlsx

Contenido: temperaturas máximas, mínimas y medias, lluvia mensual y días con nieve para Ushuaia y Río Grande.

Período utilizado: 2015–2025.

Estos datasets permiten relacionar demandas turísticas (visitas, pernoctaciones) con condiciones climáticas, lo que resulta especialmente relevante en una provincia donde el clima marca fuertemente la temporada.

Preprocesamiento y construcción del dataset final

3.1 Decisiones de calidad de datos

Durante la exploración inicial (notebook 01_exploracion_datasets.ipynb) se detectaron varios problemas que llevaron a tomar decisiones de preprocesamiento:

– Exclusión del año 2020:

En los tres datasets, 2020 presenta valores nulos o atípicos por el cierre del parque y las restricciones de la pandemia de COVID-19. Se decidió eliminar 2020 completo del análisis para no distorsionar la estacionalidad normal del turismo.

– Falta de datos de Ushuaia en 2024 (meteorología):

En el dataset meteorológico, las variables de Ushuaia (temperaturas y lluvias) no registran datos para los 12 meses de 2024. En lugar de descartar ese año, se decidió usar las variables de Río Grande como proxy, justificando que ambas ciudades se encuentran en la misma provincia y muestran un comportamiento climático similar a lo largo de la serie histórica.

– Período de trabajo final:

Después de aplicar estos filtros, se definió como período de análisis 2015–2025, excluyendo 2020. Al cruzar los tres datasets y generar un lag de un mes, el dataset final queda con 115 observaciones mensuales.

3.2 Integración de datasets

En el notebook 02_modelo_clasificacion.ipynb se realizó la integración:

Lectura de los tres archivos en pandas.

Limpieza y normalización de columnas (año, mes) y tipos de datos.

Unión de los datasets por año y mes, obteniendo para cada mes:

- Visitas al parque (total, residentes, no residentes).
- Variables climáticas (temperatura media y lluvia de Ushuaia y Río Grande).
- Pernotaciones, viajeros y estadía promedio en Ushuaia.

3.3 Construcción de variables objetivo

Se construyeron dos targets basados en la información del mes siguiente:

– nivel_temporada:

A partir de las visitas totales del mes siguiente se calcularon terciles y se definieron tres clases:

Baja: valores por debajo del primer tercil.

Media: entre el primer y el segundo tercil.

Alta: por encima del segundo tercil.

La distribución quedó equilibrada, aproximadamente 40 meses de Alta, 37 de Media y 38 de Baja.

– perfil_visitante:

Se compararon las visitas de residentes versus no residentes del mes siguiente y se definió:

Residente: si predominan las visitas de residentes.

No_Residente: si predominan las visitas de no residentes.

Aquí se encontró un fuerte desbalance: 86 meses con predominio de residentes y 29 con no residentes.

Debido a este desbalance y al tamaño reducido del dataset, se decidió utilizar nivel_temporada como objetivo principal de modelado y tratar perfil_visitante como una variable de análisis complementaria.

Análisis exploratorio de datos (EDA)

En el primer notebook se realizaron análisis básicos y, en el segundo, se generaron gráficos más detallados.

Principales hallazgos del EDA:

– Estacionalidad marcada:

El promedio de visitas por mes muestra picos claros en enero y febrero, y mínimos en mayo y junio. Esto refleja la fuerte influencia del clima en la actividad turística.




Figura 1. Promedio de visitas al Parque Nacional Tierra del Fuego por mes.

– Variación anual:

El total anual de visitas muestra una caída importante posterior a 2019, asociada a la pandemia, y una recuperación progresiva hacia 2023 y 2024, que resulta el año con mayor cantidad de visitas del período analizado.




Figura 2. Total anual de visitas al Parque Nacional Tierra del Fuego.

– Relación general entre variables:

La matriz de correlación indica una fuerte correlación positiva entre visitas al parque y pernoctaciones o viajeros en Ushuaia, así como una correlación positiva entre visitas y temperatura media. La

relación con la lluvia es más débil, mientras que la estadia promedio no se comporta de manera tan alineada con el resto de las variables.




Figura 3. Distribución de las clases de nivel_temporada y perfil_visitante

4.1 Correlaciones relevantes

La matriz de correlación entre variables numéricas muestra algunos resultados que justifican decisiones de modelado y preprocesamiento:




Figura 4. Matriz de correlación entre variables numéricas.

– Las temperaturas medias de Río Grande y Ushuaia (rg_temp_media y ush_temp_media) tienen una correlación de aproximadamente 0,97, lo que indica un comportamiento prácticamente paralelo de ambas series. Esto respalda la decisión de usar Río Grande como proxy climático de Ushuaia en 2024, cuando faltan los datos de esta última.

– Las visitas al parque (total_visitas) presentan correlaciones altas y positivas con el número de viajeros totales en Ushuaia (ush_viaj_total) y con las pernoctaciones totales (ush_pern_total). Esto sugiere que la actividad en el parque y la actividad hotelera se mueven de manera coordinada, y justifica incluir estas variables como características del modelo.

– La estadía promedio (ush_estadia_total) muestra correlaciones más moderadas o incluso negativas con algunas variables de visitas y clima, lo que indica que no siempre más turismo implica estancias

más largas. Este comportamiento se menciona como hallazgo, aunque no se explota en profundidad en el modelo actual.

– La lluvia mensual tiene correlaciones más bajas con las visitas que la temperatura media, lo que refuerza la idea de que la temperatura es el factor climático principal de la estacionalidad turística, mientras que la lluvia puede influir pero de forma más secundaria.

Estas correlaciones ayudaron a seleccionar las variables de entrada, a justificar las decisiones de proxy y a interpretar mejor el comportamiento general del sistema turístico analizado.

Modelado y evaluación

5.1 Features y preprocesamiento

Para predecir nivel_temporada se utilizaron como variables de entrada:

- Visitas del mes actual: total_visitas, residentes, no_residentes.
- Meteorología: ush_temp_media, ush_lluvia_mm, rg_temp_media, rg_lluvia_mm.
- Pernotaciones: ush_pern_total, ush_viaj_total, ush_estadia_total.
- Mes del año como variable categórica.

Se empleó un ColumnTransformer con:

- SimpleImputer con mediana y StandardScaler para las variables numéricas.
- OneHotEncoder para el mes.

Este preprocesamiento se integró en un Pipeline de scikit-learn junto con el modelo, para garantizar un flujo reproducible sin fugas de información entre entrenamiento y test.

5.2 Modelos probados

Se entrenaron dos modelos de clasificación:

K-Nearest Neighbors (KNN, $k = 5$)

Entrenado sobre el 80 por ciento de los datos, con 20 por ciento para test.




Figura 5. Matriz de confusión del modelo KNN para la variable nivel_temporada.

Resultados principales:

- Accuracy en test aproximadamente 0,74.
- F1 macro en test aproximadamente 0,74.
- Accuracy promedio en validación cruzada (5 folds) de alrededor de 0,67 con desviación 0,08.


La matriz de confusión muestra muy buenos resultados para las clases Alta y Baja temporada, y mayor confusión en la clase Media, que corresponde a meses de transición.

Árbol de Decisión (profundidad máxima 4)

Resultados principales:

- Accuracy en test aproximadamente 0,61.
- Accuracy promedio en validación cruzada aproximadamente 0,52 con desviación 0,06.

El árbol tiene peor rendimiento que KNN, pero permite analizar la importancia de variables: las visitas del mes actual, la cantidad de viajeros y el mes del año aparecen como las variables más influyentes, lo cual coincide con la intuición de estacionalidad observada en el EDA.



Figura

6. Matriz de confusión del Árbol de Decisión para nivel_temporada.



Figura 7. Estructura e importancia de variables en el Árbol de Decisión

5.3 Consideración sobre perfil_visitante

Se evaluó brevemente el uso de perfil_visitante como objetivo. Sin embargo, el fuerte desbalance (muchos meses con predominio de residentes) y el tamaño reducido del dataset implican que un modelo puede lograr accuracy alto simplemente prediciendo siempre la clase mayoritaria, sin capturar realmente los casos con predominio de no residentes. Por este motivo, se decidió no profundizar en un modelo específico para este target en este parcial y dejarlo como línea futura de trabajo.

Conclusiones y trabajos futuros

6.1 Conclusiones principales

- Es posible integrar datos oficiales de distintas fuentes del IPIEC (visitas, clima y pernoctaciones) para construir un dataset coherente que describa la actividad turística mensual del Parque Nacional Tierra del Fuego.
- El proceso de preprocesamiento fue crítico: la exclusión de 2020 y el uso de Río Grande como proxy climático de Ushuaia en 2024 permitieron trabajar con una serie más consistente y aprovechar los datos más recientes.
- El análisis exploratorio confirmó una estacionalidad muy marcada y relaciones fuertes entre clima, hotelería y visitas al parque, lo que respalda la lógica del modelo.
- Con solo 115 observaciones mensuales, el modelo KNN alcanzó un desempeño moderado, con accuracy cercano a 0,67 en validación cruzada, suficiente para diferenciar razonablemente los meses de alta y baja temporada, aunque con mayor dificultad en los meses de temporada media.

- El Árbol de Decisión, aunque menos preciso, aportó interpretabilidad sobre qué variables aportan más información a la clasificación.

6.2 Importancia del proyecto

Desde el punto de vista personal, fue importante trabajar con un caso real vinculado a Tierra del Fuego. Analizar el flujo de visitantes al Parque Nacional permite dimensionar la relevancia del turismo para la provincia y abre la puerta a herramientas que podrían ayudar a:

- Planificar mejor servicios y recursos del parque según la temporada.
- Anticipar picos de demanda para transporte, alojamiento y actividades.
- Comprender cómo factores climáticos influyen en la decisión de visitar el parque.

Aunque este es un proyecto académico, demuestra que con datos públicos y técnicas de Aprendizaje Automático accesibles (KNN, árboles de decisión, pipelines en scikit-learn) se pueden obtener modelos útiles para apoyar la toma de decisiones.

6.3 Líneas futuras

Como trabajo futuro se propone:

- Incorporar más años de datos o mayor desagregación (por ejemplo, por tipo de visitante o por actividad dentro del parque).
- Profundizar en el target perfil_visitante, aplicando técnicas específicas para clases desbalanceadas cuando se disponga de más observaciones.
- Probar otros algoritmos vistos en la materia, como máquinas de vectores de soporte (SVM), y comparar sistemáticamente su rendimiento.

– Desplegar el modelo en una herramienta sencilla (por ejemplo, un notebook interactivo) que permita simular escenarios con diferentes condiciones climáticas y niveles de pernoctaciones.

En conjunto, el proyecto permitió aplicar de forma integrada los contenidos de la materia, desde la elección y limpieza de datasets hasta el diseño y evaluación de modelos de clasificación, sobre un problema real y relevante para Tierra del Fuego.